TAREA DE APRENDIZAJE



Tipo de aprendizaje: aprendizaje supervisado.

Predicción: se busca predecir si una noticia es falsa o verdadera.

Posibles resultados:

- Noticia falsa.
- Noticia verdadera.

Tiempo de observación de los resultados: Los resultados deberían obtenerse justo después del procesamiento del modelo.



Los resultados arrojados por el modelo pueden servir en los siguientes contextos:

- Marcar noticias que podrían ser falsas.
- Advertir a consumidores de noticias acerca de estas noticias falsas.
- Generar alertas que alienten al consumidor a verificar los hechos.



Beneficiario final: Las personas que se podrían ver beneficiadas por esto son los ciudadanos que consumen noticias, medios de comunicación, plataformas digitales de noticias.

Empresa/Organización: Este es un proyecto académico que podría ser aplicado en entornos reales.

Problemas abordados: Reducción de la desinformación causada por la manipulación de noticas y prevención de manipulación electoral por parte de campañas políticas sesgadas en los medios de comunicación.

Riesgos:

- Posible sesgo en los datos de entrenamiento.
- Dificultad en la interpretabilidad de los resultados.

RECOLECCIÓN DE DATOS - NO SE DEBE DILIGENCIAR

¿Cómo se obtiene el conjunto inicial de entidades y resultados (por ejemplo, extractos de bases de datos, extracciones de API, etiquetado manual)? ¿Qué estrategias se aplican para actualizar los datos continuamente, controlando los costos y manteniendo la vigencia?



- Noticias de periódicos en línea: 'Público,' 'La Marea,' 'El Común.' Estos son datos recopilados en el contexto del curso.
- Sería posible añadir otras fuentes de información externa.



Costo/beneficio de decisiones (in)correctas:

 Marcar una noticia como falsa cuando no lo APRENDIZAJE (USO DEL MODELO)

> Modo de uso: Por lotes y en tiempo real, porque se le pasa toda la información que se posee y se espera que el

CONSTRUCCIÓN DE MODELOS

Cantidad de modelos: Se espera que se construya mínimo un modelo base con

INGENIERÍA DE CARACTERÍSTICAS

Variables utilizadas:

- es puede desacreditar fuentes confiables.
- Marcar una noticia como verdadera cuando es falsa puede permitir la difusión de desinformación.

Criterios de éxito:

- Alta precisión en la detección.
- Aceptación de la herramienta por parte de expertos en verificar estas noticias falsas.

Restricciones de equidad: Se deben mitigar sesgos en los datos y asegurar una aplicación justa en distintos contextos.

- software responda si es falsa o no en ese momento (el tiempo que se demore en analizarlo).
- Frecuencia: Dependiendo de la aplicación, puede ejecutarse con cada publicación o en intervalos regulares.

posibilidad de ajustes y especializaciones según el tipo de noticia.

Actualización: Periódica, según la evolución de la desinformación y la calidad de detección.

Tiempo de generación del modelo:

Depende de la cantidad de los datos que se tienen en el momento y cuánto tiempo tarde en construirse el análisis de estos.

- Frecuencia de palabras clave asociadas a noticias falsas.
- Análisis de sentimientos.
- Patrón de escritura y estructura del texto.
- Fuente de la noticia.

Transformaciones:

- Tokenización y limpieza del texto.
- Representación vectorial de palabras.

MONITOREO NO SE DEBE DILIGENCIAR



¿Qué métricas y KPI se utilizan para hacer un seguimiento del impacto de la solución de ML una vez desplegada, tanto para los usuarios finales como para la empresa? ¿Con qué frecuencia deben revisarse?

Adaptación de OWNML MACHINE LEARNING CANVAS



Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a <u>Creative Commons Attribution-ShareAlike 4.0 International License</u>. Please keep this mention and the link to <u>ownml.co</u> when sharing.

OWNML.CO